KAPU mérések

Egy, a modell számára ismeretlen tudásfájlon (PixelLab-dokumentáció, 206 899 token) a KAPU-t használó ügynök kérésenként 4 104 tokent olvasott, az egy Markdown-fájlban kereső 8 280, az ugyanezt PDF-ként kereső 8 207 tokent (medián, mindháromnál ugyanaz a feladatszöveg). Helyes válasz: KAPU 12, Markdown 12, PDF 11 a 12-ből, három vak bíráló szerint.

Legutóbbi mérés: 2026-10-28 · tools 0.5.0, specification v1.3, format 1.3 · Windows 11, release build · minden szám a repó bench/results/ mappájából jön

KAPU	Egy .md fájl kereséssel	PDF kereséssel	Az egész fájl a kontextusban
4 104	8 280	8 207	206 899
token/kérés (medián)	token/kérés (medián)	token/kérés (medián)	token minden kérésnél

A v3-as terv: kontextuális modell tiszta Rustban (0.5.0)

Mérve 2026-10-28, tools 0.5.0, specification v1.3, format 1.3, a v2-es terv hét kérdéshalmazán és dev/teszt felosztásán (577 teszt-kérdés), a teszt rész eredményével. A 0.3 statikus modellje korlátozta a hibrid keresést, ezért a v3-as terv más beágyazó modelleket mért, és a nyertest, a multilingual-e5-small-t beépítette a KAPU-ba: a saját Rust kódja pontos egész szorzatokkal futtatja a modellt, így egy vektor minden gépen ugyanazokból a bitekből áll, és a fájl minden vektort komponensenként 4 biten tárol.

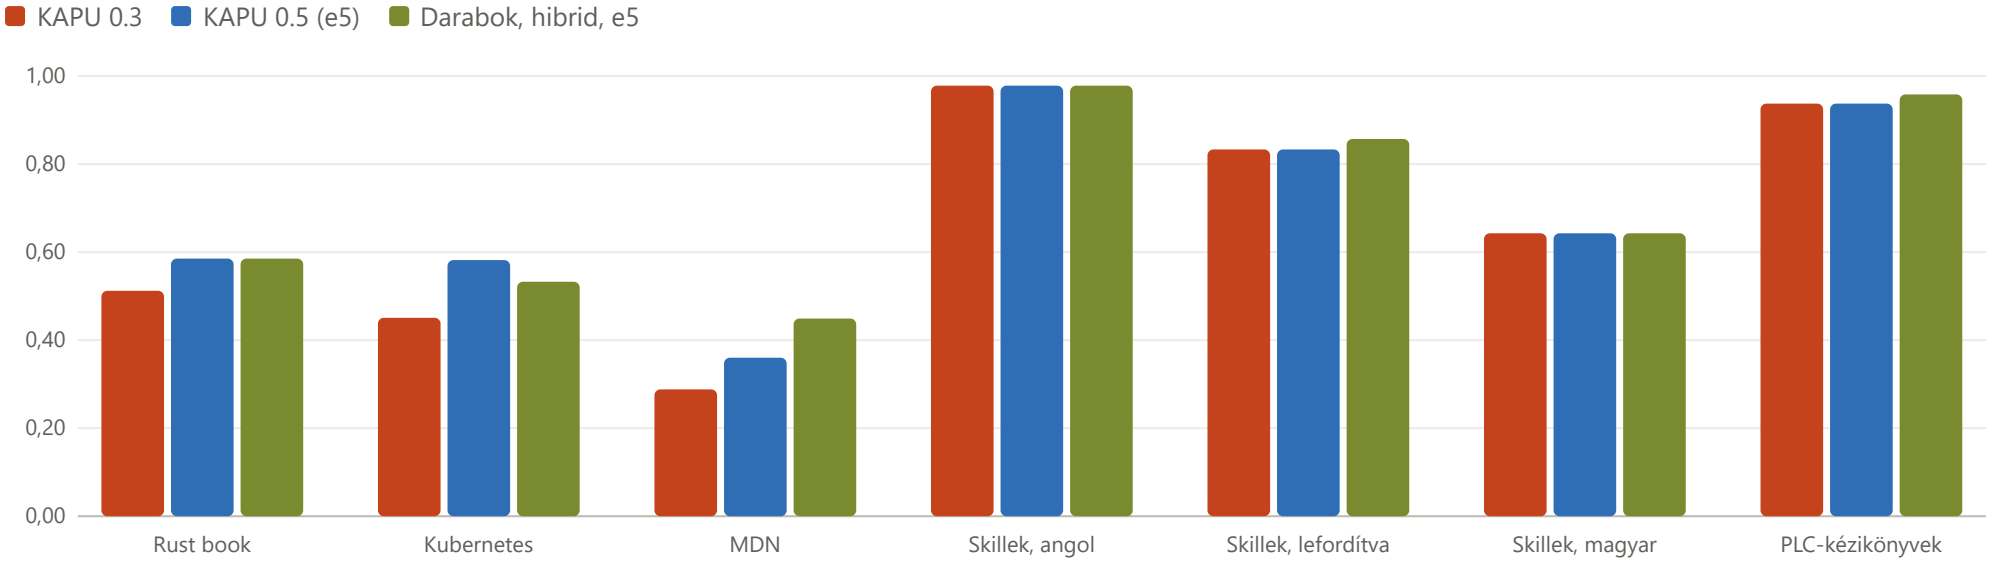
A modellcsere a KAPU saját keresőjében

Eltérés a 0.3 statikus modelljétől az alap rangsorral, teszt rész, a halmazok összevonva, 95%-os páros bootstrap intervallum. Legrosszabb halmaz: egy halmaz legnagyobb vesztesége bármelyik mérőszámban; p50 arány: a leglassabb halmaz medián keresési ideje a 0.3-hoz képest. A csere nem megy át a 0.3.0 M0 szabályán (legrosszabb halmaz legfeljebb -0,01, legfeljebb 1,5-szer lassabb); a 0.5.0-hoz ezekkel az árakkal elfogadtuk.

Modell	Bit	Rangsor	Δ szobaszintű recall@10	Δ szobaszintű MRR@10	Legrosszabb halmaz	p50 arány
multilingual-e5-small	8	Alap rangsor	+0,062 [+0,035, +0,090]	+0,027 [+0,005, +0,049]	−0,065	14,9×
multilingual-e5-small	4	Alap rangsor	+0,062 [+0,035, +0,090]	+0,028 [+0,006, +0,052]	−0,056	14,9×
multilingual-e5-small	4	Passzus-BM25	+0,069 [+0,038, +0,101]	+0,038 [+0,014, +0,062]	−0,070	14,6×
multilingual-e5-small	4	Passzus-BM25 és szobafúzió	+0,075 [+0,045, +0,106]	+0,038 [+0,014, +0,063]	−0,085	14,5×

Halmazonként: 0.3, 0.5 és a darabolós hibrid ugyanazzal a modellel

Szobaszintű recall@10 a teszt részen, alap rangsor, 4 bit. Keresési idő: a kapu bench mediánja, a kérdés vektora AVX-512-re fordítva, és a kiadás alap (SSE2) fordításával.



Kérdéskészlet	Kérdés	recall@10, 0.3	recall@10, 0.5	MRR@10, 0.3	MRR@10, 0.5	Keresés, 0.3	Keresés, 0.5	0.5, SSE2
Rust book	41	0,512	0,585	0,252	0,263	0,8 ms	12,6 ms	35,0 ms
Kubernetes	122	0,451	0,582	0,253	0,271	27,1 ms	25,7 ms	48,4 ms
MDN	236	0,288	0,360	0,135	0,195	408,5 ms	155,9 ms	320,4 ms
Skillek, angol	46	0,978	0,978	0,853	0,868	10,1 ms	17,2 ms	43,1 ms
Skillek, lefordítva	42	0,833	0,833	0,759	0,770	12,7 ms	17,6 ms	—
Skillek, magyar	42	0,643	0,643	0,492	0,436	10,7 ms	18,9 ms	—
PLC-kézikönyvek	48	0,938	0,938	0,734	0,751	29,7 ms	30,1 ms	—

Mibe kerül: fájlméret és build-idő

Az első build a modellel 12 szálon (AVX-512 fordítás). Egy újraépítés a kiszámolt ablakokat a gyorsítótár naplójából veszi, és csak az új szöveget számolja.

Fájl	Méret, 0.3	Méret, 0.5	Növekedés	8 bittel	Első build
Rust book	2,4 MB	2,6 MB	+9%	+20%	71 s
Kubernetes	28,1 MB	31,4 MB	+12%	+25%	922 s
MDN	139,0 MB	160,7 MB	+16%	+34%	2 986 s
Skillek, angol	5,9 MB	6,5 MB	+10%	+21%	124 s
PLC-kézikönyvek	12,3 MB	13,4 MB	+9%	+20%	321 s

Hogyan tároljunk egy vektort (a darabokon szimulálva)

A KAPU BM25 a darabok vektoraival összefésülve, eltérés a lebegőpontos vektortól. Középre tolt: előbb minden vektorból levonjuk az átlagukat; maradék: a vektor és az átlag különbségének kódja, az eredeti koszinusszal pontozva. A 0.3 előjelbitjei ezzel a modellel összeomlanak, a 4 bit a KAPU-ban mérve semmibe sem kerül.

Tárolás	Bájt ablakonként	Δ szobaszintű recall@10	Δ szobaszintű MRR@10
lebegőpontos, középre tolt	1 536	−0,021 [−0,042, +0,000]	−0,002 [−0,015, +0,011]
előjelbit, utána 8 bit	432	**−0,121 [−0,154, −0,088]**	**−0,066 [−0,089, −0,044]**
8 bit	384	+0,002 [+0,000, +0,005]	**+0,003 [+0,001, +0,006]**
előjelbit, utána 4 bit	240	**−0,127 [−0,159, −0,095]**	**−0,074 [−0,096, −0,051]**
középre tolt előjelbit, utána 4 bit	240	−0,012 [−0,033, +0,009]	−0,001 [−0,014, +0,011]
4 bit, maradék	194	−0,009 [−0,023, +0,005]	−0,002 [−0,010, +0,006]
4 bit	192	−0,012 [−0,028, +0,003]	−0,001 [−0,010, +0,007]
4 bit, középre tolt	192	−0,017 [−0,038, +0,003]	−0,004 [−0,016, +0,009]
3 lépcső, középre tolt	144	−0,019 [−0,040, +0,002]	+0,002 [−0,011, +0,015]
-1/0/+1, maradék	98	**−0,035 [−0,055, −0,014]**	**−0,024 [−0,041, −0,007]**
-1/0/+1, középre tolt	96	−0,021 [−0,043, +0,002]	−0,005 [−0,018, +0,009]
előjelbit, maradék	50	**−0,080 [−0,109, −0,052]**	**−0,063 [−0,085, −0,041]**
előjelbit (mint a 0.3-ban)	48	**−0,203 [−0,239, −0,168]**	**−0,178 [−0,208, −0,149]**
előjelbit, középre tolt	48	**−0,033 [−0,055, −0,010]**	−0,010 [−0,025, +0,005]

A jelöltek ugyanazokon a darabokon (V1)

Három modell az 512 tokenes darabokon, Pythonban, eltérés a 0.3 statikus modelljétől: csak a vektorok, a szokásos darabolós hibrid, és a KAPU BM25-rangsora szobaszinten összefésülve a modell vektoraival.

Modell	Rangsor	Δ szobaszintű recall@10	Δ szobaszintű MRR@10
potion-retrieval-32M	Csak vektor	+0,021 [−0,017, +0,059]	+0,016 [−0,010, +0,042]
potion-retrieval-32M	Darabolós hibrid	−0,007 [−0,033, +0,019]	+0,002 [−0,019, +0,023]
potion-retrieval-32M	KAPU BM25 + vektor	+0,003 [−0,026, +0,033]	+0,009 [−0,013, +0,032]
potion-retrieval-32M	KAPU passzus-BM25 + vektor	+0,009 [−0,021, +0,038]	+0,022 [−0,000, +0,044]
multilingual-e5-small-qint8	Csak vektor	**+0,123 [+0,083, +0,163]**	**+0,072 [+0,042, +0,102]**
multilingual-e5-small-qint8	Darabolós hibrid	**+0,064 [+0,036, +0,092]**	**+0,039 [+0,016, +0,062]**
multilingual-e5-small-qint8	KAPU BM25 + vektor	**+0,071 [+0,040, +0,102]**	**+0,039 [+0,016, +0,063]**
multilingual-e5-small-qint8	KAPU passzus-BM25 + vektor	**+0,075 [+0,045, +0,104]**	**+0,053 [+0,030, +0,076]**

- A modell a kulcs: a multilingual-e5-small-lal a szobaszintű recall@10 az alap rangsorral +0,062, passzus-BM25-tel és szobafúzióval +0,075 értékkel javul, mindkét intervallum nulla fölött. Kubernetes 0,451 helyett 0,582, MDN 0,288 helyett 0,360.
- Ára: a magyar kérdések az angol skilleken MRR-t veszítenek (0,492 helyett 0,436), egy kis fájlban a keresés 0,8 ms helyett 12,6 ms (a kérdés vektora; alap fordítással 35,0 ms), és a fájlok 9-16%-kal nőnek. Egy nagy fájl gyorsabb (408,5 ms helyett 155,9 ms), mert olvasáskor semmi sem pontozódik újra.
- Ugyanazzal a modellel a szokásos darabolós hibrid a Rust könyvön 0,585, a Kubernetesen 0,533, az MDN-en 0,449: egy szinten van a KAPU 0.5-tel, alatta, illetve fölötte. A KAPU előnye továbbra is a szakaszos találat a tokenárával, egy fájlban, szerver nélkül.
- A kódoló a KAPU saját Rust kódja, új függőség és futás közbeni letöltés nélkül: egész szorzatok, rögzített sorrendű lebegőpontos összegek, saját exp és erf, így az SSE2, AVX2 és AVX-512 fordítás ugyanazokat a bájtokat írja. Az ONNX Runtime-mal 0,998-1,000 koszinusszal egyezik; egy 512 tokenes ablak egy szálon 0,45 s (AVX-512), alap fordítással 1,3 s.

A v2-es terv 1-3. fázisa: ablációs keret, egy javítás, amely megáll, tisztességes alapvonalak

Mérve 2026-10-27, tools 0.3.0. A v2-es terv minden rangsorolási változtatása kapcsoló, alapból kikapcsolva; kikapcsolva a rangsor bitre a 0.2.1-esé. Minden kérdéssor egyszer, a kérdés hash-e szerint két részre oszlik: dev (40%, összesen 356 kérdés) és teszt (60%, 577); a javítások

változatát a dev részen választottuk, és csak a teszt rész eredménye szerepel. Egy javítás akkor marad, ha a teszt részen a szobaszintű recall@10 vagy MRR@10 javul, a 95%-os páros bootstrap intervallum nulla fölött van (a halmazok összevonva), egyik halmaz sem romlik 0,01-nél többet, és a keresés legfeljebb 1,5-szer lassabb.

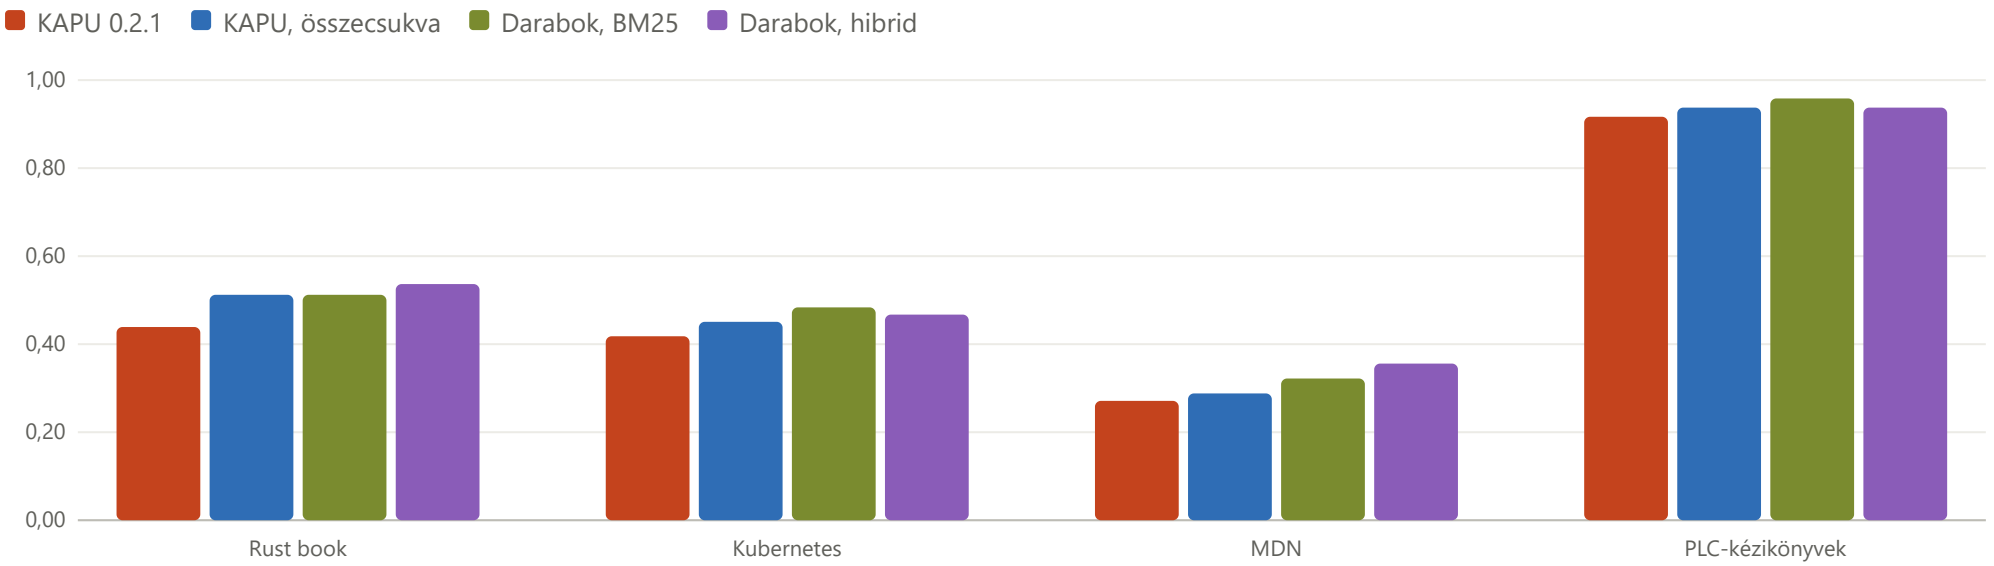
Melyik javítás megy át

Eltérés az alaprangsortól a teszt részen, a halmazok összevonva, a 95%-os bootstrap intervallummal. Zöld: az intervallum nulla fölött; piros: alatta. Legrosszabb halmaz: egy halmaz legnagyobb romlása a két metrika valamelyikében.

Javítás	A dev részen választott változat	Δ szobaszintű recall@10	Δ szobaszintű MRR@10	Legrosszabb halmaz	Marad
Szótövezés: csak a szó, angol vagy magyar tő (M0 tengely)	stem-en	+0,002 [−0,012, +0,016]	−0,005 [−0,014, +0,004]	**−0,021**	nem
J2a: külön átlaghossz a szobákra és a szakaszokra	avgdl-split	**+0,021 [+0,005, +0,036]**	**+0,016 [+0,003, +0,028]**	**−0,022**	nem
J2b: a szakasz a szobája pontszámának egy részét kapja	parent-0.1	−0,004 [−0,019, +0,012]	**−0,009 [−0,018, −0,000]**	**−0,030**	nem
J1: szobánként egy találat, a többi illeszkedő szakasz megnevezve	collapse-1	**+0,022 [+0,010, +0,035]**	**+0,011 [+0,008, +0,014]**	+0,000	igen
J4a: a BM25 első 50 találata mindig kap vektorpontot	rescore-bm25-50	+0,002 [−0,005, +0,010]	+0,001 [−0,002, +0,005]	**−0,021**	nem
J10: a 40 token alatti szakaszok csak a szobájukon át	min-door-40	−0,002 [−0,009, +0,004]	+0,001 [−0,001, +0,004]	−0,009	nem
J4c: kérdésfüggő súly (kódszó, ismeretlen szó)	adaptive-1.5	+0,002 [−0,005, +0,009]	+0,000 [−0,003, +0,003]	**−0,021**	nem
J4b: súlyozott RRF (BM25 1-3, vektor 0,5-1, k 20 vagy 60)	rrf-b1-v0.7-k60	+0,009 [−0,005, +0,024]	**+0,006 [+0,001, +0,012]**	**−0,048**	nem
J4d: min-max pontszám a rang helyett	convex-b1-v1	+0,002 [−0,017, +0,021]	+0,004 [−0,008, +0,016]	**−0,024**	nem

Visszakeresés a darabolós alapvonalakkal szemben (teszt rész)

Szobaszint: találat a várt oldal bármelyik ajtaja. A darabolós alapvonal minden oldalt 512 tokenes darabokra vág, és egy oldalt egyszer számol (deduplikálva): ez a tisztességes összevetés a KAPU szobaszintjével. Összecsukott: szobánként egy találat (J1), az új alapbeállítás.



Kérdéskészlet	Kérdés	Rangsor	recall@1	Recall@10	recall@100	MRR@10	nDCG@10
Rust book	41	KAPU 0.2.1	0,146	0,439	0,902	0,220	0,271
Rust book	41	KAPU, összecsukva	0,146	0,512	0,902	0,252	0,314
Rust book	41	Darabok, BM25	0,146	0,512	0,902	0,255	0,315
Rust book	41	Darabok, vektor	0,122	0,439	0,854	0,223	0,274
Rust book	41	Darabok, hibrid	0,146	0,537	0,829	0,249	0,317
Kubernetes	122	KAPU 0.2.1	0,139	0,418	0,713	0,238	0,282
Kubernetes	122	KAPU, összecsukva	0,139	0,451	0,713	0,253	0,302
Kubernetes	122	Darabok, BM25	0,164	0,484	0,795	0,242	0,299
Kubernetes	122	Darabok, vektor	0,066	0,328	0,639	0,145	0,189
Kubernetes	122	Darabok, hibrid	0,164	0,467	0,738	0,250	0,301
MDN	236	KAPU 0.2.1	0,076	0,271	0,525	0,127	0,161
MDN	236	KAPU, összecsukva	0,076	0,288	0,525	0,135	0,171

Kérdéskészlet	Kérdés	Rangsor	recall@1	Recall@10	recall@100	MRR@10	nDCG@10
MDN	236	Darabok, BM25	0,089	0,322	0,602	0,156	0,196
MDN	236	Darabok, vektor	0,064	0,203	0,517	0,095	0,120
MDN	236	Darabok, hibrid	0,064	0,356	0,631	0,145	0,195
Skillek, angol	46	KAPU 0.2.1	0,783	0,978	1,000	0,846	0,878
Skillek, angol	46	KAPU, összecsukva	0,783	0,978	1,000	0,853	0,884
Skillek, lefordítva	42	KAPU 0.2.1	0,714	0,833	0,833	0,756	0,775
Skillek, lefordítva	42	KAPU, összecsukva	0,714	0,833	0,833	0,759	0,777
Skillek, magyar	42	KAPU 0.2.1	0,405	0,619	0,762	0,487	0,520
Skillek, magyar	42	KAPU, összecsukva	0,405	0,643	0,762	0,492	0,529
PLC-kézikönyvek	48	KAPU 0.2.1	0,625	0,917	0,979	0,720	0,767
PLC-kézikönyvek	48	KAPU, összecsukva	0,625	0,938	0,979	0,734	0,783
PLC-kézikönyvek	48	Darabok, BM25	0,625	0,958	0,979	0,741	0,794
PLC-kézikönyvek	48	Darabok, vektor	0,458	0,792	0,896	0,571	0,625
PLC-kézikönyvek	48	Darabok, hibrid	0,583	0,938	0,979	0,686	0,746

Miért marad ki egy kérdés (M3)

Minden tesztkérdés, amelynek oldala nincs a hibrid első 10-ben, az első illő osztály szerint: duplikáció (szobánként egy találattal az első 10-ben lenne), fúzió (az egyik rangsor első 10-ében benne volt), újrapontozás (jó BM25-találat vektorpont nélkül), rangsorolás (az első 100-ban van), szókincs (sehol). Összevonás: az oldal az első 10-ben van, de a várt szakasz nincs.

Kérdéskészlet	Rangsor	Kimaradt	Duplikáció	Fúzió	Újrapontozás	Rangsorolás	Szókincs	Összevonás
Rust book	KAPU 0.2.1	23	3	5	1	10	4	1
Rust book	KAPU, összecsukva	20	0	5	1	10	4	8
Kubernetes	KAPU 0.2.1	71	4	11	6	15	35	9
Kubernetes	KAPU, összecsukva	67	0	11	6	15	35	26
MDN	KAPU 0.2.1	172	4	17	15	24	112	8
MDN	KAPU, összecsukva	168	0	17	15	24	112	23
Skillek, angol	KAPU 0.2.1	1	0	0	0	1	0	2
Skillek, angol	KAPU, összecsukva	1	0	0	0	1	0	15
Skillek, lefordítva	KAPU 0.2.1	7	0	0	0	0	7	1
Skillek, lefordítva	KAPU, összecsukva	7	0	0	0	0	7	7
Skillek, magyar	KAPU 0.2.1	16	1	1	0	4	10	2
Skillek, magyar	KAPU, összecsukva	15	0	1	0	4	10	7
PLC-kézikönyvek	KAPU 0.2.1	4	1	1	0	1	1	1
PLC-kézikönyvek	KAPU, összecsukva	3	0	1	0	1	1	21

kapu_ask: mit nyit ki egy hívás (J12)

Megvan: a várt oldal egy kerete a kinyitottak között. Szétosztott: az első 5 szoba legjobb ajtajának eleje, a 2000 tokenes keret megosztva. Magabiztosság: a legjobb találat egyedül, ha egyértelműen elöl van, különben szétosztott, és a válasz kiírja: confidence: high vagy low. Token a várt oldal nélkül: a mellé ment válaszok tokenje kérdésenként. Keresési találat: hány fér a 600 tokenes keresési válaszba.

Kérdéskészlet	Mód	Megvan	Válasz tokenje	Token a várt oldal nélkül	Keresési találat
Rust book	Legjobb találat (összecsukva)	15%	1 662	1 336	7,2
Rust book	Legjobb találat (0.2.1)	15%	1 653	1 315	10,0
Rust book	Szétosztva 5 szobára	41%	1 224	710	7,2
Rust book	Csak kivonatok, semmi sincs kinyitva	0%	215	211	7,2
Rust book	Magabiztosság, arány 1,1	37%	1 239	835	7,2
Rust book	Magabiztosság, arány 1,3	41%	1 226	711	7,2
Rust book	Magabiztosság, arány 1,6	41%	1 226	713	7,2
Rust book	Legjobb találat, kétsoros kivonat (J11)	15%	1 664	1 336	5,9
Kubernetes	Legjobb találat (összecsukva)	17%	1 824	1 404	8,6
Kubernetes	Legjobb találat (0.2.1)	17%	1 800	1 391	9,9
Kubernetes	Szétosztva 5 szobára	39%	1 130	678	8,6
Kubernetes	Magabiztosság, arány 1,3	39%	1 155	721	8,6
Kubernetes	Legjobb találat, kétsoros kivonat (J11)	17%	1 823	1 406	7,0
MDN	Legjobb találat (összecsukva)	12%	1 678	1 344	9,5
MDN	Legjobb találat (0.2.1)	11%	1 614	1 331	10,0
MDN	Szétosztva 5 szobára	22%	1 124	854	9,5
MDN	Magabiztosság, arány 1,3	21%	1 140	892	9,5
MDN	Legjobb találat, kétsoros kivonat (J11)	12%	1 682	1 344	7,8
Skillek, angol	Legjobb találat (összecsukva)	83%	1 827	301	5,3
Skillek, angol	Legjobb találat (0.2.1)	83%	1 788	295	9,8
Skillek, angol	Szétosztva 5 szobára	96%	1 145	51	5,3
Skillek, angol	Csak kivonatok, semmi sincs kinyitva	0%	209	210	5,3
Skillek, angol	Magabiztosság, arány 1,1	93%	1 186	85	5,3
Skillek, angol	Magabiztosság, arány 1,3	96%	1 151	52	5,3
Skillek, angol	Magabiztosság, arány 1,6	96%	1 148	51	5,3

Kérdéskészlet	Mód	Megvan	Válasz tokenje	Token a várt oldal nélkül	Keresési találat
Skillek, angol	Legjobb találat, kétsoros kivonat (J11)	83%	1 828	300	4,7
Skillek, lefordítva	Legjobb találat (összecsukva)	76%	1 794	372	5,3
Skillek, lefordítva	Legjobb találat (0.2.1)	76%	1 684	384	9,6
Skillek, lefordítva	Szétosztva 5 szobára	81%	1 144	210	5,3
Skillek, lefordítva	Csak kivonatok, semmi sincs kinyitva	0%	217	217	5,3
Skillek, lefordítva	Magabiztosság, arány 1,1	79%	1 193	249	5,3
Skillek, lefordítva	Magabiztosság, arány 1,3	81%	1 148	210	5,3
Skillek, lefordítva	Magabiztosság, arány 1,6	81%	1 148	211	5,3
Skillek, lefordítva	Legjobb találat, kétsoros kivonat (J11)	76%	1 796	372	4,6

Megfelelnek-e a témacsoportok a dokumentáció mappáinak? (N13)

A forrás második mappaszintje (Kubernetes concepts/workloads, MDN web/css). ARI: 0 a véletlen, 1 ugyanaz a csoportosítás; zárójelben az NMI azonos méretű véletlen csoportokkal. k-means: ugyanannyi csoport a szobavektorokból. sim és term: Leiden csak az adott éltípuson. Legnagyobb csoport: szoba / token.

Kérdéskészlet	Szobák	Csoportok / mappák	ARI	NMI (véletlen)	k-means ARI	csak sim	csak term	Legnagyobb csoport
Kubernetes	1 722	104 / 73	0,159	0,416 (0,150)	0,137	0,155	−0,005	166 / 1 509 243
MDN	14 719	99 / 50	0,040	0,390 (0,029)	0,032	0,041	−0,001	733 / 1 296 318

- Egy javítás áll meg, és a 0.3.0 alapbeállítása: szobánként egy találat, alatta a szoba többi illeszkedő szakasza. A teszt részen, a hét halmaz összevonva: szobaszintű recall@10 +0,022 [95% +0,010, +0,035], MRR@10 +0,011 [+0,008, +0,014], egyik halmaz sem romlik, a keresési idő ugyanannyi (Kubernetes p50 27,3 helyett 27,9 ms, MDN 313,5 helyett 313,8 ms).
- Három változtatás közel jár, de egy kis halmazon egy kérdést veszít, többet, mint amit a szabály enged: külön átlaghossz a szobákra és a szakaszokra (+0,021 recall@10), 1,5-ös BM25-súly k=20-szal az összecsukás mellett (+0,028), és ugyanez kérdésfüggő súllyal (+0,032). Kapcsolóként maradnak, kikapcsolva. A gráflépés, a többi fúzió, a szótövezés és a címsúly változatai nem adnak mérhető javulást.
- Tisztességes alapvonal: az oldalanként deduplikált darabolós BM25 a Kubernetesen (0,484 a 0,451-gyel szemben) és az MDN-en (0,322 a 0,288-cal szemben) még mindig a KAPU előtt van, a darabolós hibrid a PLC-kézikönyvek kivételével mindenütt. A README a 0.2.1-ig a

darabonként számolt oszloppal vetett össze. Az MDN-en a kimaradások zöme szókincs: 168-ból 112 oldal egyik első 100-ban sincs benne.

- A kapu_ask most az első 5 szoba elejét nyitja ki egy közös keretben: a várt szoba a válaszban 15% helyett 42% (Rust könyv), 17% helyett 39% (Kubernetes), 12% helyett 22% (MDN), 83% helyett 96% (skillek), körülbelül 1800 helyett 1130 tokenből. A tervezett magabiztossági jel nincs kalibrálva (ahol „high", ott a Kubernetesen és az MDN-en 11%), ezért nem jelenik meg.
- A modell számára ismeretlen PLC-kézikönyveken (hat gyártó, 623 oldal) a Claude Sonnet a KAPU-eszközökkel 92%-ban válaszolt helyesen, a jó oldallal a promptban 97%-ban, egymagában 28%-ban. 24 olyan kérdésnél, amelyre a kézikönyvek nem felelnek, a KAPU-s ügynök 23-szor mondta ki, hogy nincs benne; egymagában a modell 11-szer talált ki választ. Kérdésenként egy futás; a kérdésíró látta az oldalakat.
- A gráf a navigációt segíti, nem a rangsort: a naplózott élő futások 27 későbbi kinyitásából 5 (19%) jött szomszédlistáról (link 2 a 64 megmutatottból, sim 3/64, term 0/221), kinyitott ajtónként 70 tokenért. A témacsoportok a dokumentáció mappáit a szobavektorokon futó k-means szintjén követik, és ezt a szerkezetet a sim élek hordozzák.

1.2-es fájlformátum: vektorok a fájlban, válaszok kereten belül

Mérve: 2026-10-26, tools 0.2.0, specification v1.2, file format 1.2, ugyanazokon a korpuszokon, kérdéseken és gépen, mint az 1.1-es formátumot, és egy negyedik korpuszon: ügynöki skillek és frontend-jegyzetek, 77 angol és 60 magyar kérdéssel. A keresővektorok most a fájlban vannak, minden ablakvektor minden komponenséből egy előjelbit. Az előjelbitek kiválasztják a 200 legjobb jelöltet, ezeket a modell lebegőpontos vektorai rendezik, így másik gépen az első keresés is gyorsítótár nélkül megy. Minden MCP-válasz a saját árával kezdődik és a max_tokens kereten belül marad, a kapu_ask pedig egy hívásban keres és kinyit.

A második jegyzőkönyv követelményei

A 2026-10-26-i jegyzőkönyv mérhető követelményei és elfogadási határaik. Token: o200k_base.

Azonosító	Követelmény	Cél	Mért	Teljesül
K-01	Eszközleírások és bemeneti sémák, mind a hat eszköz	≤ 800	797	igen
K-02	Első térképválasz 3000 szobás fájlon	≤ 1 000	306	igen
K-05	Keresési válasz, 10 találat kivonattal (a legnagyobb bármelyik korpuszon)	≤ 600	586	igen
K-07	Egyetlen kapu_ask hívásból megválaszolt kérdések (skill-korpusz)	≥ 70%	83,1%	igen
K-11	A #VEC szakasz miatti fájlnövekedés (a legnagyobb korpusz, MDN)	≤ 3%	3,3%	nem
K-12	Magyar kérdés angol skillekre, lefordítva: hibrid recall@10	≥ 0,75	0,78	igen
K-13	Ugyanez fordítás nélkül (ehhez másik beágyazómodell kell)	≥ 0,60	0,55	nem
K-22	Ajtó kinyitása 3000 szobás fájlon (medián)	< 20 ms	7,6 ms	igen

Négy korpusz 1.2-es formátumban

Fájlméret a vektorszakasz előtt és után. Az idők és a válaszméretek MCP-n mért mediánok, kivéve a legnagyobb keresési választ; token: amit az ügynök kap.

Korpusz	Fájl, v1.1 (MiB)	Fájl, v1.2 (MiB)	Növekedés	Keresés (ms)	Kinyitás (ms)	Első térkép (token)	Következő térkép (token)	Keresés (token)	Legnagyobb keresés (token)	kapu_ask (token)	Egy kapu_ask hívásból megválaszolva
Rust Book	2,21	2,24	1,7%	32	3,6	328	159	527	580	1 657	21%
Kubernetes	26,22	26,78	2,2%	50	7,9	967	983	528	586	1 795	20%
MDN	128,34	132,52	3,3%	282	48	969	980	500	583	1 664	12%
Skillek és jegyzetek	5,56	5,67	2,0%	26	2,9	600	224	547	585	1 786	83%

Visszakeresés: szobaszintű recall@10, hibrid rangsor

Az előjelbitek önmagukban rontottak az MDN-en, a skilleken, és leginkább magyar kérdésnél angol szövegre. A legjobb jelöltek lebegőpontos újrapontozásával mindenhol a lebegőpontos szinten vagy fölötte vannak; az ára a keresési idő.

Kérdéskészlet	Kérdés	v1.1, lebegőpontos vektorok	v1.2, csak előjelbitek	v1.2, előjelbitek + újrapontozás
Rust Book (Stack Overflow)	68	0,485	0,500	0,485
Kubernetes (Stack Overflow)	201	0,458	0,458	0,458
MDN (Stack Overflow)	395	0,271	0,246	**0,278**
Skillek, angol kérdések	77	0,948	0,922	**0,961**
Skillek, magyar kérdések	60	0,633	0,583	0,633
Skillek, a magyar kérdések lefordítva	60	—	0,833	0,833

Még nincs mérve

- Skillek megtalálása 250 skillel (a tesztgépen 91 van), és olyan feladatszöveggel, amely nem említi a skilleket, így az ügynöknek magától kell rájuk gondolnia.
- Helyi modell (Ollama) mint ügynök.
- Más kliens, mint a Claude Code: a Codex CLI és a VS Code konfigurációja benne van a README-ben, de nincs kipróbálva, és velük mérés nem is tervezett.

Skillek megtalálása: natív Claude Code skillek, egy KAPU fájl, egy Markdown-mappa

12 valós fejlesztési feladat (landing oldal, MCP-szerver, Claude Code plugin, akadozó API, Office-fájlok és mások), mindegyikhez előre rögzítve 2-4 egyértelműen releváns skill, összesen 39. Ugyanazok a skillek háromféle formában, 45 és 91 darab (a 91 a tesztgép összes valódi skillje). Minden feladat formánként és méretenként egyszer futott, opus modellel, claude -p-vel (Claude Code 2.1.310), 2026-10-26. A feladatszöveg rámutat a skillekre, ahogy egy felhasználó tenné: töltsd be a Skill eszközzel az összes releváns skillt; keresd meg és nyisd ki a KAPU fájlban az összes releváns skillt; keresd meg és olvasd el ebben a mappában az összes releváns skillt. Egy skill akkor számít megtaláltnak, ha a Skill eszköz betöltötte, valamelyik fájlját elolvasta, vagy valamelyik szobáját kinyitotta.

Eredmények formánként

Téves: betöltötte, pedig a feladathoz nem kell, és észszerűen sem használható. Token/feladat: a futás összes bemeneti tokenje, minden kör beszámítva (medián). $/feladat: amit a Claude Code API-áron jelent, a gyorsítótárból olvasott tokent a kisebb áron (medián). Fix költség: egy skillt nem igénylő munkamenet első köre; a natív skill-lista minden munkamenet rendszerpromptjában benne van.

Skill	Forma	Megtalált releváns skill	Feladat, ahol mind meglett	Tévesen betöltött skill	Token/feladat	$/feladat	Hívás/feladat	Másodperc/feladat	Fix költség munkamenetenként (token)
45	Natív skillek	38 / 39 (97%)	11 / 12	0	42 574	$0,224	4	9	12 652
45	KAPU fájl, katalógus (0.2.1)	38 / 39 (97%)	11 / 12	3	58 266	$0,131	5,5	25	4 775
45	KAPU fájl (0.2.0)	37 / 39 (95%)	10 / 12	0	77 215	$0,229	7,5	30	4 774
45	Markdown-mappa	39 / 39 (100%)	12 / 12	14	93 176	$0,283	10,5	24	5 430
91	Natív skillek	39 / 39 (100%)	12 / 12	0	44 953	$0,236	4	12	14 081
91	KAPU fájl, katalógus (0.2.1)	38 / 39 (97%)	11 / 12	3	48 972	$0,099	5	22	4 775
91	KAPU fájl (0.2.0)	38 / 39 (97%)	11 / 12	0	88 418	$0,255	9	33	4 774
91	Markdown-mappa	39 / 39 (100%)	12 / 12	12	107 726	$0,336	10,5	33	5 430

- Ha a skillek katalógusa egy válaszban jön (tools 0.2.1: kapu_map kind=skill, D154), a KAPU fájl ugyanannyit talál meg, mint korábban (91 skillnél 39-ből 38), de 9 helyett 5 hívásban, feladatonként 48 972 bemeneti tokenből (korábban 88 418; natív skillek: 44 953). Feladatonként $0,099 az ára, kevesebb, mint a natív skilleké ($0,236), két okból: skillenként csak az első részt nyitja ki (legfeljebb 2000 token, a többit kérésre), a Skill eszköz viszont az egész skillt betölti; és kevesebb új szöveg kerül a prompt-gyorsítótárba, amelynek írása a bemeneti ár kétszerese, olvasása a tizede.
- A natív skillek továbbra is a legtöbbet találják meg (91 skillnél 39-ből 39), és semmit nem töltenek be tévesen. A KAPU fájl egy feladatnál 3 fölösleges skillt is betöltött, és egyet nem talált meg (frontend-expert a Figma-feladatnál; 45 skillnél a natív sem). A korábban kimaradt magyar nyelvű skillt most a katalógusból megtalálja.
- A Markdown-mappa minden skillt megtalált, de 91 skillnél 12 olyat is elolvasott, ami nem kellett, és ez a legdrágább ($0,336 feladatonként).
- Egy munkamenet fix költsége: a KAPU-eszközökkel 4 775 token, akárhány skill van, a natív lista 45 skillnél 12 652, 91-nél 14 081. 250 skillt nem mértünk: a tesztgépen csak 91 van. Csak a KAPU-futások ismétlődtek; a natív és a Markdown-futások az első körből valók.

1.1-es fájlformátum: kisebb fájl, gyorsabb hívás, jobb jelentés szerinti keresés

Három változás a pilot után, ugyanazokon a korpuszokon és kérdéseken újramérve. Az index az ajtó azonosítója helyett a sorszámát tárolja, így a fájl kb. 4,5-ször kisebb, és a 13 millió tokenes MDN-korpusz már a kiadott eszközzel is megépül. Egy hívás a fájlt egyszer dolgozza fel és ellenőrzi, az indexsort bináris kereséssel találja meg. A jelentés szerinti keresés ajtónként 512 tokenes ablakonként egy vektort használ, és a legjobb ablak számít.

Előtte és utána

Szobaszintű recall@10: a várt oldal bármely része az első 10 találat között. Az MDN a v1.0.4-gyel kísérleti, 64 MiB-os sorhatárú buildből.

Mérőszám	Korpusz	v1.0.4	v1.1
Fájlméret (MiB)	Rust book	7,6	2,2
Fájlméret (MiB)	Kubernetes	117,4	26,2
Fájlméret (MiB)	MDN	542,2	128,3
Megépül a kiadott eszközzel	MDN	nem (E005)	igen
Keresés MCP-n (ms, medián)	Rust book	56	12,8
Keresés MCP-n (ms, medián)	Kubernetes	657	19,2
Keresés MCP-n (ms, medián)	MDN	3 172	158,2
Ajtó kinyitása MCP-n (ms, medián)	Rust book	17	2,4
Ajtó kinyitása MCP-n (ms, medián)	Kubernetes	216	4,9
Ajtó kinyitása MCP-n (ms, medián)	MDN	1 040	44,1
Szobaszintű recall@10, hibrid	Rust book	0,5	0,5
Szobaszintű recall@10, hibrid	Kubernetes	0,4	0,5
Szobaszintű recall@10, hibrid	MDN	0,3	0,3
Szobaszintű recall@10, csak vektor	Rust book	0,3	0,4
Szobaszintű recall@10, csak vektor	Kubernetes	0,3	0,3
Szobaszintű recall@10, csak vektor	MDN	0,2	0,1
kapu bench futásideje (s)	Kubernetes	187	8
kapu bench futásideje (s)	MDN	1 774	127

Ugyanaz a tartalom háromféle formában: KAPU, egy Markdown-fájl, PDF

A PixelLab-dokumentáció (harmadik féltől, nem publikus), egy kezdő indie-fejlesztő 12 kérése. A Markdown- és a PDF-ügynök rákeresett a szövegre, és csak a talált részt olvasta el: a Markdown-fájl sorait, a PDF oldalait. Ha az egész fájlt bemásolnánk a beszélgetésbe, minden kérés 206 899 tokenbe kerülne. Három vak Claude Sonnet bíráló minden állítást a dokumentációhoz mért.

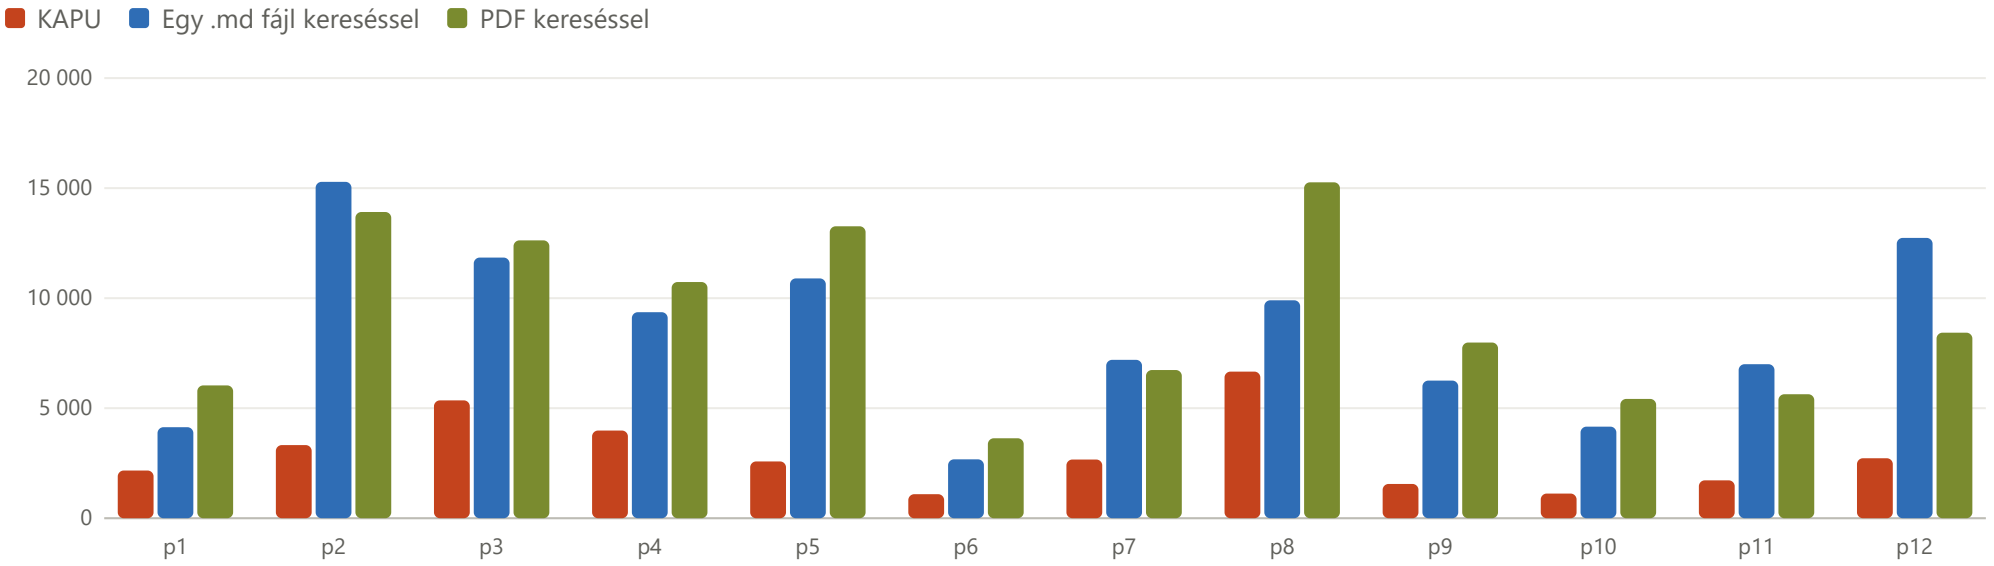
Második kör: mindhárom forma ugyanazzal a feladatszöveggel

KAPU a v1.0.4-es specifikációval. A Markdown- és a PDF-válaszok az első körből valók, új bírálók pontozták őket.

Forma	Helyes	Részben	Alátámasztott állítás	Összes állítás	Hasznosság (1-5)	Token/kérés	Token, 12 kérés	Hívás/kérés
KAPU	12	0	153	157	4,17	4 104	48 557	4
Egy .md fájl kereséssel	12	0	140	145	4,00	8 280	101 452	8
PDF kereséssel	11	1	147	151	3,83	8 207	109 675	6

Első kör: olvasott token kérésenként

KAPU a v1.0.3-as specifikációval, saját feladatszöveggel. Token: amit az eszközök visszaadtak az ügynöknek (o200k_base).



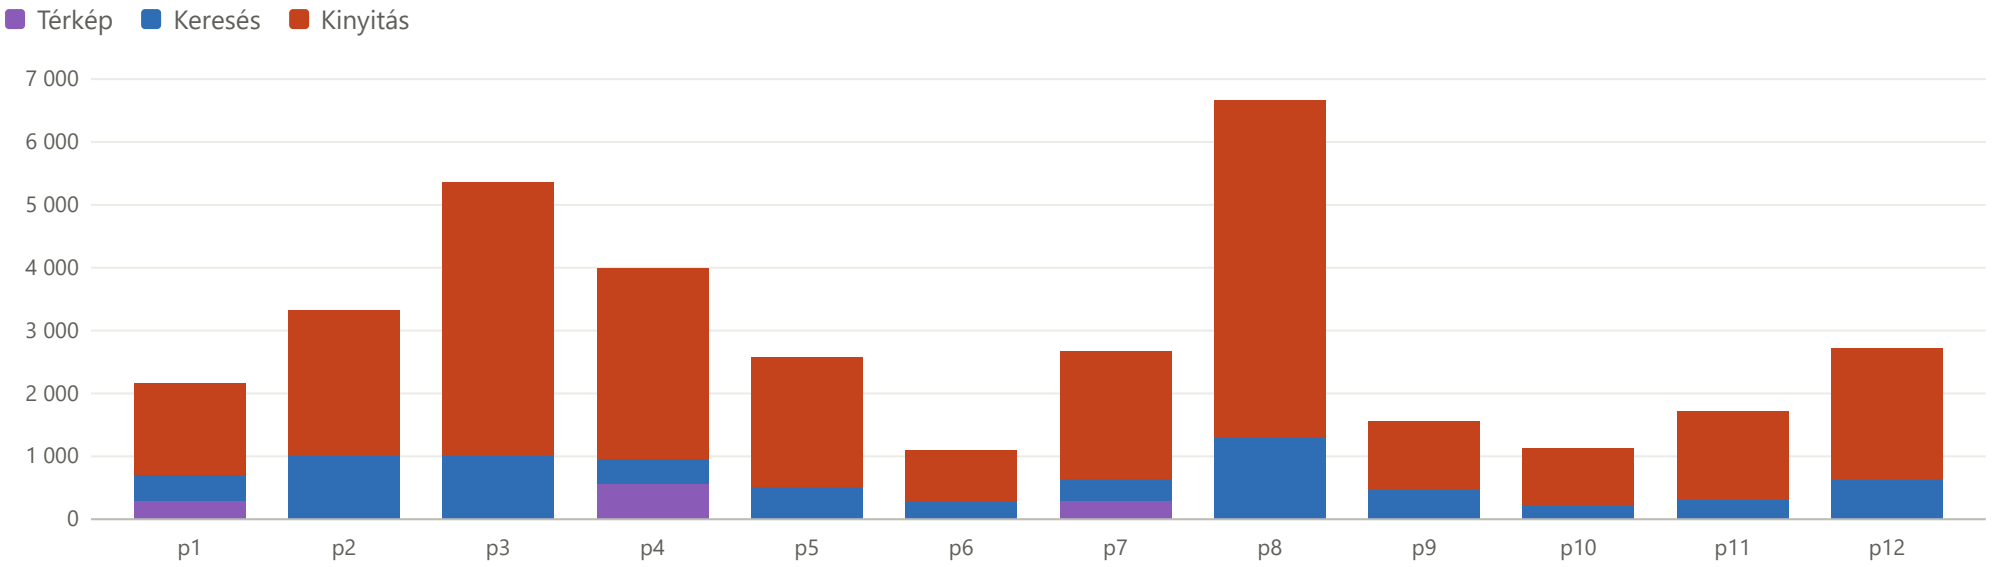
Forma	Helyes	Részben	Alátámasztott állítás	Összes állítás	Hasznosság (1-5)	Token/kérés	Token, 12 kérés	Hívás/kérés
KAPU	12	0	122	123	4,08	2 624	34 953	3
Egy .md fájl kereséssel	12	0	134	138	4,25	8 280	101 452	8
PDF kereséssel	11	1	146	151	4,33	8 207	109 675	6

Miért több ezer token, ha a térkép csak pár száz?

A térkép és a keresés csak a tartalomjegyzék és a találati lista. A tokenek zöme a kinyitott ajtókból jön: ez az a dokumentációszöveg, amiből a válasz készül. A 12 kérés KAPU-tokenjeiből a kinyitás 77%, a keresés 20%, a térkép 3%.

KAPU-tokenek kérésenként, hívásfajta szerint

Egy kérés jellemzően: 1-2 keresés (300-400 token), 1-2 kinyitott ajtó (1-3 ezer token), ritkán térkép.



Skálázás: kicsi, közepes és nagy dokumentáció

S: a Rust Book, M: a Kubernetes-dokumentáció, L: az MDN Web Docs, mind 1.1-es formátumban. Egy MCP-munkamenetben: a térkép, minden csoportlista, 20 keresés a szobacímekkel mint lekérdezéssel, és minden első találat kinyitása.

Build, méret és válaszok

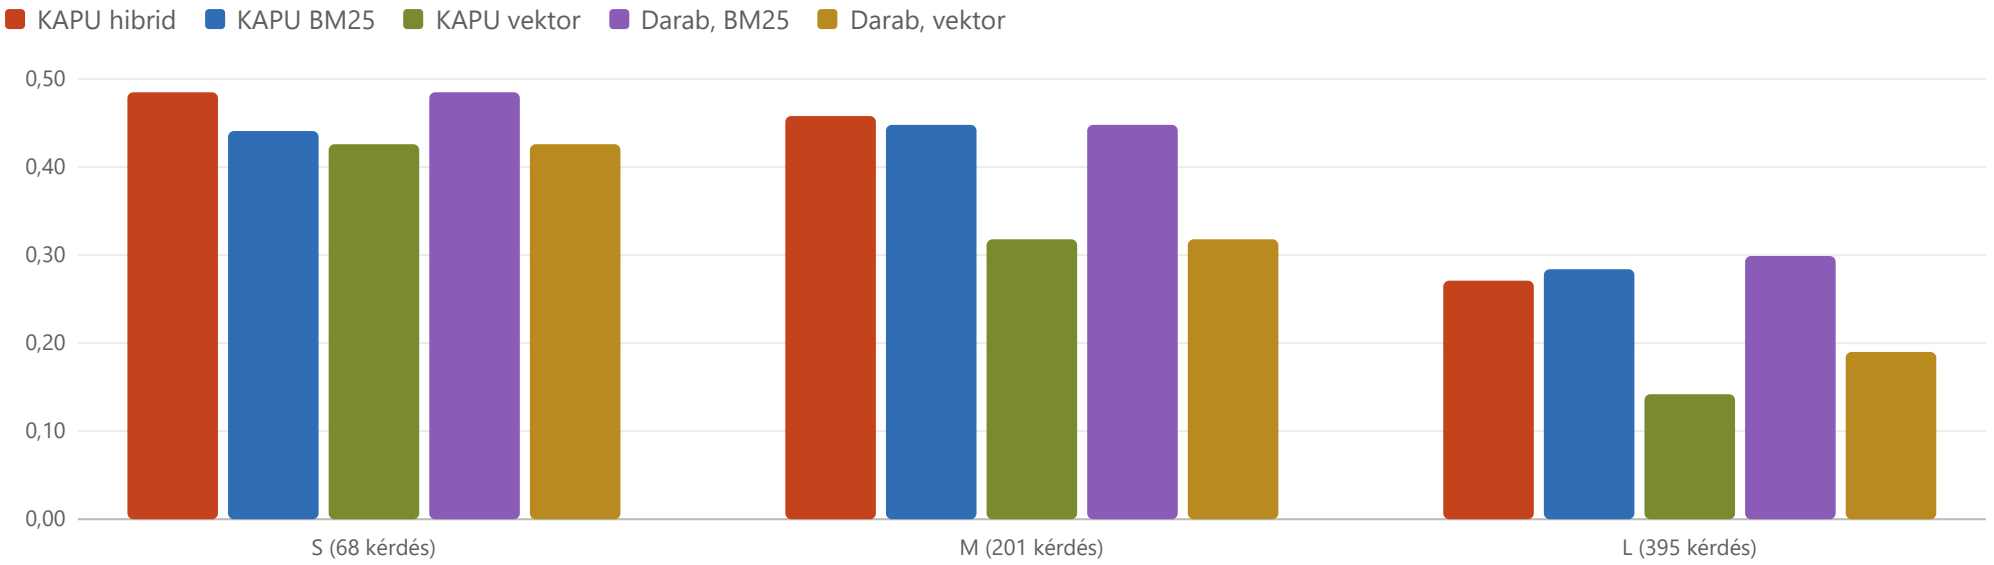
Méret	Korpusz	Tudás (token)	Szoba	Ajtó	Csoport	Build (s)	Memória (GB)	Fájl (MiB)	Térkép (token)	Első térkép (token)	Legnagyobb csoportlista (token)	Keresés (token)	Keresés (ms)	Első keresés (s)	Kinyitás (token)	Kinyitás (ms)
S	Rust book	321 618	111	231	7	4,6	0,69	2,2	153	322	804	246	12,8	1,1	1 689	2,4
M	Kubernetes	3 873 333	1 722	6 370	104	38	1,03	26,2	1 950	2 318	6 957	260	19,2	1	240	4,9
L	MDN	12 995 136	14 719	84 910	99	240,3	2,68	128,3	1 921	2 303	30 118	212	158,2	1,3	366	44,1

Visszakeresés ügynök nélkül: KAPU kontra darabolós RAG

Valódi Stack Overflow-kérdések, ahol az elfogadott válasz pontosan egy dokumentációoldalra hivatkozik: 68, 201 és 395 kérdés. Találat: az oldal bármely része az első találatok között. A darabolós alapvonal 512 tokenes darabokkal, 64 token átfedéssel és ugyanazzal a beágyazómodellel dolgozik.

Szobaszintű recall@10 méret és módszer szerint

A KAPU ajtókat ad vissza (szobákat és fejezeteiket), az alapvonal darabokat.



Méret	Módszer	Kérdés	Recall@5	Recall@10	MRR@10
S	KAPU hibrid	68	0,397	0,485	0,281
S	KAPU BM25	68	0,338	0,441	0,259
S	KAPU vektor	68	0,353	0,426	0,184
S	Darab, BM25	68	0,426	0,485	0,282
S	Darab, vektor	68	0,368	0,426	0,230
M	KAPU hibrid	201	0,373	0,458	0,245
M	KAPU BM25	201	0,348	0,448	0,218
M	KAPU vektor	201	0,219	0,318	0,147
M	Darab, BM25	201	0,338	0,448	0,218
M	Darab, vektor	201	0,249	0,318	0,145
L	KAPU hibrid	395	0,172	0,271	0,128
L	KAPU BM25	395	0,220	0,284	0,135
L	KAPU vektor	395	0,086	0,142	0,055
L	Darab, BM25	395	0,230	0,299	0,159

Méret	Módszer	Kérdés	Recall@5	Recall@10	MRR@10
L	Darab, vektor	395	0,124	0,190	0,081

Élő próba a Rust Bookon: öt rendszer, 30 kérdés

Ezekre a népszerű kérdésekre a modell fejből is jól válaszolt (zárt könyv: 30-ból 30), ezért itt a pontosság nem különbözteti meg a rendszereket, a költség igen. KAPU a v1.0.3-as specifikációval; a v1.0.4-gyel a KAPU-ügynökök kérdésenként mediánban 2331 tokent olvastak, azonos pontossággal.

Helyes válaszok és költség rendszerenként

Két vak bíráló (Claude Sonnet és Haiku). Az ügynök összes tokenje: a teljes futás a kérdésekre osztva, közelítés.

Rendszer	Helyes (Sonnet-bíráló)	Helyes (Haiku-bíráló)	Kérdés	Olvasott token/kérdés	Hívás/kérdés	Ügynök összes tokenje/kérdés
Zárt könyv, eszköz nélkül	30	28	30	0	0	2 706
Ügynöki darabolós RAG	30	27	30	4 150	1	12 648
grep/read a Markdown-mappán	29	28	30	1 290	2	9 343
llms.txt	30	29	30	8 738	2	11 615
KAPU	30	29	30	3 982	2	10 118

Korábbi javítókör: a v1.0.4-es specifikáció

Mérőszám	v1.0.3	v1.0.4
KAPU a Rust Bookon: olvasott token/kérdés (medián)	3 982	2 331
KAPU a Rust Bookon: helyes válasz (30-ból)	30	30
Első térképhívás, Kubernetes (token)	4 989	2 318
Első térképhívás, MDN (token)	4 139	2 303

Módszer és korlátok

- Korpuszok: a Rust Book (MIT vagy Apache-2.0), a Kubernetes-dokumentáció (CC BY 4.0) és az MDN Web Docs (CC BY-SA 2.5), rögzített commitokon. Kérdések: Stack Overflow API (CC BY-SA); csak az azonosítóik vannak tárolva.
- Ügynökök: Claude Sonnet alügynökök, csak naplózott eszközökkel. A tokenszámlálás o200k_base.
- Bírálók: vak Claude-modellek; a válaszok véletlen betűk alatt, a forrásjelölő sorok nélkül.
- Ez pilot egyetlen gépen (Windows 11, release build), nem benchmark. A PixelLab-fájl harmadik féltől való, nem publikus.

Repó RESULTS.md Nyers számok (JSON)