KAPU mérések

Egy, a modell számára ismeretlen tudásfájlon (PixelLab-dokumentáció, 206 899 token) a KAPU-t használó ügynök kérésenként 4 104 tokent olvasott, az egy Markdown-fájlban kereső 8 280, az ugyanezt PDF-ként kereső 8 207 tokent (medián, mindháromnál ugyanaz a feladatszöveg). Helyes válasz: KAPU 12, Markdown 12, PDF 11 a 12-ből, három vak bíráló szerint.

Legutóbbi mérés: 2026-10-26 · tools 0.2.0, specification v1.2, file format 1.2 · Windows 11, release build · minden szám a repó bench/results/ mappájából jön

KAPU	Egy .md fájl kereséssel	PDF kereséssel	Az egész fájl a kontextusban
4 104	8 280	8 207	206 899
token/kérés (medián)	token/kérés (medián)	token/kérés (medián)	token minden kérésnél

1.2-es fájlformátum: vektorok a fájlban, válaszok kereten belül

Mérve: 2026-10-26, tools 0.2.0, specification v1.2, file format 1.2, ugyanazokon a korpuszokon, kérdéseken és gépen, mint az 1.1-es formátumot, és egy negyedik korpuszon: ügynöki skillek és frontend-jegyzetek, 77 angol és 60 magyar kérdéssel. A keresővektorok most a fájlban vannak, minden ablakvektor minden komponenséből egy előjelbit. Az előjelbitek kiválasztják a 200 legjobb jelöltet, ezeket a modell lebegőpontos vektorai rendezik, így másik gépen az első keresés is gyorsítótár nélkül megy. Minden MCP-válasz a saját árával kezdődik és a max_tokens kereten belül marad, a kapu_ask pedig egy hívásban keres és kinyit.

A második jegyzőkönyv követelményei

A 2026-10-26-i jegyzőkönyv mérhető követelményei és elfogadási határaik. Token: o200k_base.

Azonosító	Követelmény	Cél	Mért	Teljesül
K-01	Eszközleírások és bemeneti sémák, mind a hat eszköz	≤ 800	797	igen
K-02	Első térképválasz 3000 szobás fájlon	≤ 1 000	306	igen
K-05	Keresési válasz, 10 találat kivonattal (a legnagyobb bármelyik korpuszon)	≤ 600	586	igen
K-07	Egyetlen kapu_ask hívásból megválaszolt kérdések (skill-korpusz)	≥ 70%	83,1%	igen
K-11	A #VEC szakasz miatti fájlnövekedés (a legnagyobb korpusz, MDN)	≤ 3%	3,3%	nem
K-12	Magyar kérdés angol skillekre, lefordítva: hibrid recall@10	≥ 0,75	0,78	igen
K-13	Ugyanez fordítás nélkül (ehhez másik beágyazómodell kell)	≥ 0,60	0,55	nem
K-22	Ajtó kinyitása 3000 szobás fájlon (medián)	< 20 ms	7,6 ms	igen

Négy korpusz 1.2-es formátumban

Fájlméret a vektorszakasz előtt és után. Az idők és a válaszméretek MCP-n mért mediánok, kivéve a legnagyobb keresési választ; token: amit az ügynök kap.

Korpusz	Fájl, v1.1 (MiB)	Fájl, v1.2 (MiB)	Növekedés	Keresés (ms)	Kinyitás (ms)	Első térkép (token)	Következő térkép (token)	Keresés (token)	Legnagyobb keresés (token)	kapu_ask (token)	Egy kapu_ask hívásból megválaszolva
Rust Book	2,21	2,24	1,7%	32	3,6	328	159	527	580	1 657	21%
Kubernetes	26,22	26,78	2,2%	50	7,9	967	983	528	586	1 795	20%
MDN	128,34	132,52	3,3%	282	48	969	980	500	583	1 664	12%
Skillek és jegyzetek	5,56	5,67	2,0%	26	2,9	600	224	547	585	1 786	83%

Visszakeresés: szobaszintű recall@10, hibrid rangsor

Az előjelbitek önmagukban rontottak az MDN-en, a skilleken, és leginkább magyar kérdésnél angol szövegre. A legjobb jelöltek lebegőpontos újrapontozásával mindenhol a lebegőpontos szinten vagy fölötte vannak; az ára a keresési idő.

Kérdéskészlet	Kérdés	v1.1, lebegőpontos vektorok	v1.2, csak előjelbitek	v1.2, előjelbitek + újrapontozás
Rust Book (Stack Overflow)	68	0,485	0,500	0,485
Kubernetes (Stack Overflow)	201	0,458	0,458	0,458
MDN (Stack Overflow)	395	0,271	0,246	**0,278**
Skillek, angol kérdések	77	0,948	0,922	**0,961**
Skillek, magyar kérdések	60	0,633	0,583	0,633
Skillek, a magyar kérdések lefordítva	60	—	0,833	0,833

Még nincs mérve

- Skillek megtalálása 250 skillel (a tesztgépen 91 van), és olyan feladatszöveggel, amely nem említi a skilleket, így az ügynöknek magától kell rájuk gondolnia.
- Helyi modell (Ollama) mint ügynök.
- Más kliens, mint a Claude Code: a Codex CLI és a VS Code konfigurációja benne van a README-ben, de nincs kipróbálva, és velük mérés nem is tervezett.

Skillek megtalálása: natív Claude Code skillek, egy KAPU fájl, egy Markdown-mappa

12 valós fejlesztési feladat (landing oldal, MCP-szerver, Claude Code plugin, akadozó API, Office-fájlok és mások), mindegyikhez előre rögzítve 2–4 egyértelműen releváns skill, összesen 39. Ugyanazok a skillek háromféle formában, 45 és 91 darab (a 91 a tesztgép összes valódi skillje). Minden feladat formánként és méretenként egyszer futott, opus modellel, claude -p-vel (Claude Code 2.1.310), 2026-10-26. A feladatszöveg rámutat a skillekre, ahogy egy felhasználó tenné: töltsd be a Skill eszközzel az összes releváns skillt; keresd meg és nyisd ki a KAPU fájlban az összes releváns skillt; keresd meg és olvasd el ebben a mappában az összes releváns skillt. Egy skill akkor számít megtaláltnak, ha a Skill eszköz betöltötte, valamelyik fájlját elolvasta, vagy valamelyik szobáját kinyitotta.

Eredmények formánként

Téves: betöltötte, pedig a feladathoz nem kell, és észszerűen sem használható. Token/feladat: a futás összes bemeneti tokenje, minden kör beszámítva (medián). $/feladat: amit a Claude Code API-áron jelent, a gyorsítótárból olvasott tokent a kisebb áron (medián). Fix költség: egy skillt nem igénylő munkamenet első köre; a natív skill-lista minden munkamenet rendszerpromptjában benne van.

Skill	Forma	Megtalált releváns skill	Feladat, ahol mind meglett	Tévesen betöltött skill	Token/feladat	$/feladat	Hívás/feladat	Másodperc/feladat	Fix költség munkamenetenként (token)
45	Natív skillek	38 / 39 (97%)	11 / 12	0	42 574	$0,224	4	9	12 652
45	KAPU fájl, katalógus (0.2.1)	38 / 39 (97%)	11 / 12	3	58 266	$0,131	5,5	25	4 775
45	KAPU fájl (0.2.0)	37 / 39 (95%)	10 / 12	0	77 215	$0,229	7,5	30	4 774
45	Markdown-mappa	39 / 39 (100%)	12 / 12	14	93 176	$0,283	10,5	24	5 430
91	Natív skillek	39 / 39 (100%)	12 / 12	0	44 953	$0,236	4	12	14 081
91	KAPU fájl, katalógus (0.2.1)	38 / 39 (97%)	11 / 12	3	48 972	$0,099	5	22	4 775
91	KAPU fájl (0.2.0)	38 / 39 (97%)	11 / 12	0	88 418	$0,255	9	33	4 774
91	Markdown-mappa	39 / 39 (100%)	12 / 12	12	107 726	$0,336	10,5	33	5 430

- Ha a skillek katalógusa egy válaszban jön (tools 0.2.1: kapu_map kind=skill, D154), a KAPU fájl ugyanannyit talál meg, mint korábban (91 skillnél 39-ből 38), de 9 helyett 5 hívásban, feladatonként 48 972 bemeneti tokenből (korábban 88 418; natív skillek: 44 953). Feladatonként $0,099 az ára, kevesebb, mint a natív skilleké ($0,236), két okból: skillenként csak az első részt nyitja ki (legfeljebb 2000 token, a többit kérésre), a Skill eszköz viszont az egész skillt betölti; és kevesebb új szöveg kerül a prompt-gyorsítótárba, amelynek írása a bemeneti ár kétszerese, olvasása a tizede.
- A natív skillek továbbra is a legtöbbet találják meg (91 skillnél 39-ből 39), és semmit nem töltenek be tévesen. A KAPU fájl egy feladatnál 3 fölösleges skillt is betöltött, és egyet nem talált meg (frontend-expert a Figma-feladatnál; 45 skillnél a natív sem). A korábban kimaradt magyar nyelvű skillt most a katalógusból megtalálja.
- A Markdown-mappa minden skillt megtalált, de 91 skillnél 12 olyat is elolvasott, ami nem kellett, és ez a legdrágább ($0,336 feladatonként).
- Egy munkamenet fix költsége: a KAPU-eszközökkel 4 775 token, akárhány skill van, a natív lista 45 skillnél 12 652, 91-nél 14 081. 250 skillt nem mértünk: a tesztgépen csak 91 van. Csak a KAPU-futások ismétlődtek; a natív és a Markdown-futások az első körből valók.

1.1-es fájlformátum: kisebb fájl, gyorsabb hívás, jobb jelentés szerinti keresés

Három változás a pilot után, ugyanazokon a korpuszokon és kérdéseken újramérve. Az index az ajtó azonosítója helyett a sorszámát tárolja, így a fájl kb. 4,5-ször kisebb, és a 13 millió tokenes MDN-korpusz már a kiadott eszközzel is megépül. Egy hívás a fájlt egyszer dolgozza fel és ellenőrzi, az indexsort bináris kereséssel találja meg. A jelentés szerinti keresés ajtónként 512 tokenes ablakonként egy vektort használ, és a legjobb ablak számít.

Előtte és utána

Szobaszintű recall@10: a várt oldal bármely része az első 10 találat között. Az MDN a v1.0.4-gyel kísérleti, 64 MiB-os sorhatárú buildből.

Mérőszám	Korpusz	v1.0.4	v1.1
Fájlméret (MiB)	Rust book	7,6	2,2
Fájlméret (MiB)	Kubernetes	117,4	26,2
Fájlméret (MiB)	MDN	542,2	128,3
Megépül a kiadott eszközzel	MDN	nem (E005)	igen
Keresés MCP-n (ms, medián)	Rust book	56	12,8
Keresés MCP-n (ms, medián)	Kubernetes	657	19,2
Keresés MCP-n (ms, medián)	MDN	3 172	158,2
Ajtó kinyitása MCP-n (ms, medián)	Rust book	17	2,4
Ajtó kinyitása MCP-n (ms, medián)	Kubernetes	216	4,9
Ajtó kinyitása MCP-n (ms, medián)	MDN	1 040	44,1
Szobaszintű recall@10, hibrid	Rust book	0,5	0,5
Szobaszintű recall@10, hibrid	Kubernetes	0,4	0,5
Szobaszintű recall@10, hibrid	MDN	0,3	0,3
Szobaszintű recall@10, csak vektor	Rust book	0,3	0,4
Szobaszintű recall@10, csak vektor	Kubernetes	0,3	0,3
Szobaszintű recall@10, csak vektor	MDN	0,2	0,1
kapu bench futásideje (s)	Kubernetes	187	8
kapu bench futásideje (s)	MDN	1 774	127

Ugyanaz a tartalom háromféle formában: KAPU, egy Markdown-fájl, PDF

A PixelLab-dokumentáció (harmadik féltől, nem publikus), egy kezdő indie-fejlesztő 12 kérése. A Markdown- és a PDF-ügynök rákeresett a szövegre, és csak a talált részt olvasta el: a Markdown-fájl sorait, a PDF oldalait. Ha az egész fájlt bemásolnánk a beszélgetésbe, minden kérés 206 899 tokenbe kerülne. Három vak Claude Sonnet bíráló minden állítást a dokumentációhoz mért.

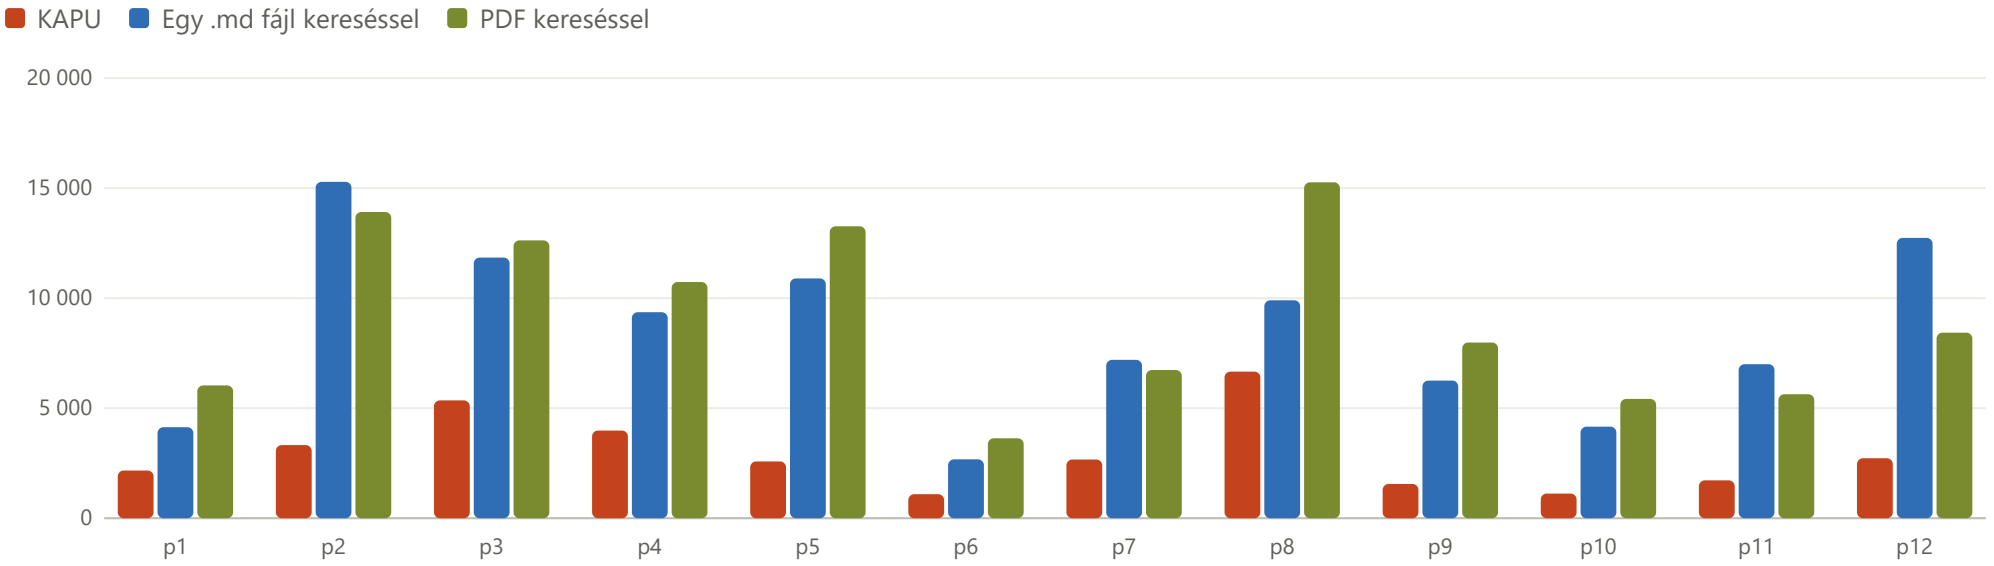
Második kör: mindhárom forma ugyanazzal a feladatszöveggel

KAPU a v1.0.4-es specifikációval. A Markdown- és a PDF-válaszok az első körből valók, új bírálók pontozták őket.

Forma	Helyes	Részben	Alátámasztott állítás	Összes állítás	Hasznosság (1–5)	Token/kérés	Token, 12 kérés	Hívás/kérés
KAPU	12	0	153	157	4,17	4 104	48 557	4
Egy .md fájl kereséssel	12	0	140	145	4,00	8 280	101 452	8
PDF kereséssel	11	1	147	151	3,83	8 207	109 675	6

Első kör: olvasott token kérésenként

KAPU a v1.0.3-as specifikációval, saját feladatszöveggel. Token: amit az eszközök visszaadtak az ügynöknek (o200k_base).



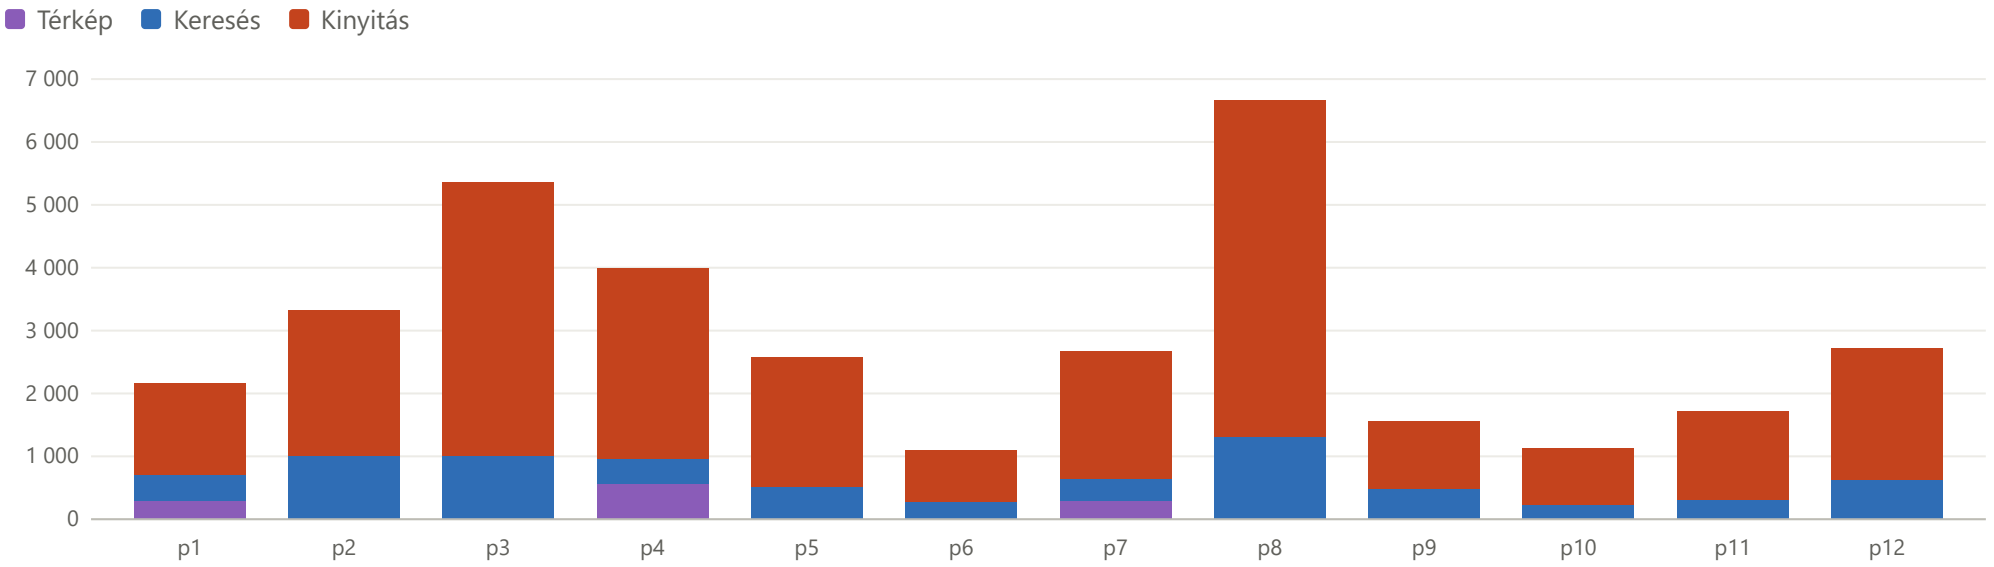
Forma	Helyes	Részben	Alátámasztott állítás	Összes állítás	Hasznosság (1–5)	Token/kérés	Token, 12 kérés	Hívás/kérés
KAPU	12	0	122	123	4,08	2 624	34 953	3
Egy .md fájl kereséssel	12	0	134	138	4,25	8 280	101 452	8
PDF kereséssel	11	1	146	151	4,33	8 207	109 675	6

Miért több ezer token, ha a térkép csak pár száz?

A térkép és a keresés csak a tartalomjegyzék és a találati lista. A tokenek zöme a kinyitott ajtókból jön: ez az a dokumentációszöveg, amiből a válasz készül. A 12 kérés KAPU-tokenjeiből a kinyitás 77%, a keresés 20%, a térkép 3%.

KAPU-tokenek kérésenként, hívásfajta szerint

Egy kérés jellemzően: 1–2 keresés (300–400 token), 1–2 kinyitott ajtó (1–3 ezer token), ritkán térkép.



Skálázás: kicsi, közepes és nagy dokumentáció

S: a Rust Book, M: a Kubernetes-dokumentáció, L: az MDN Web Docs, mind 1.1-es formátumban. Egy MCP-munkamenetben: a térkép, minden csoportlista, 20 keresés a szobacímekkel mint lekérdezéssel, és minden első találat kinyitása.

Build, méret és válaszok

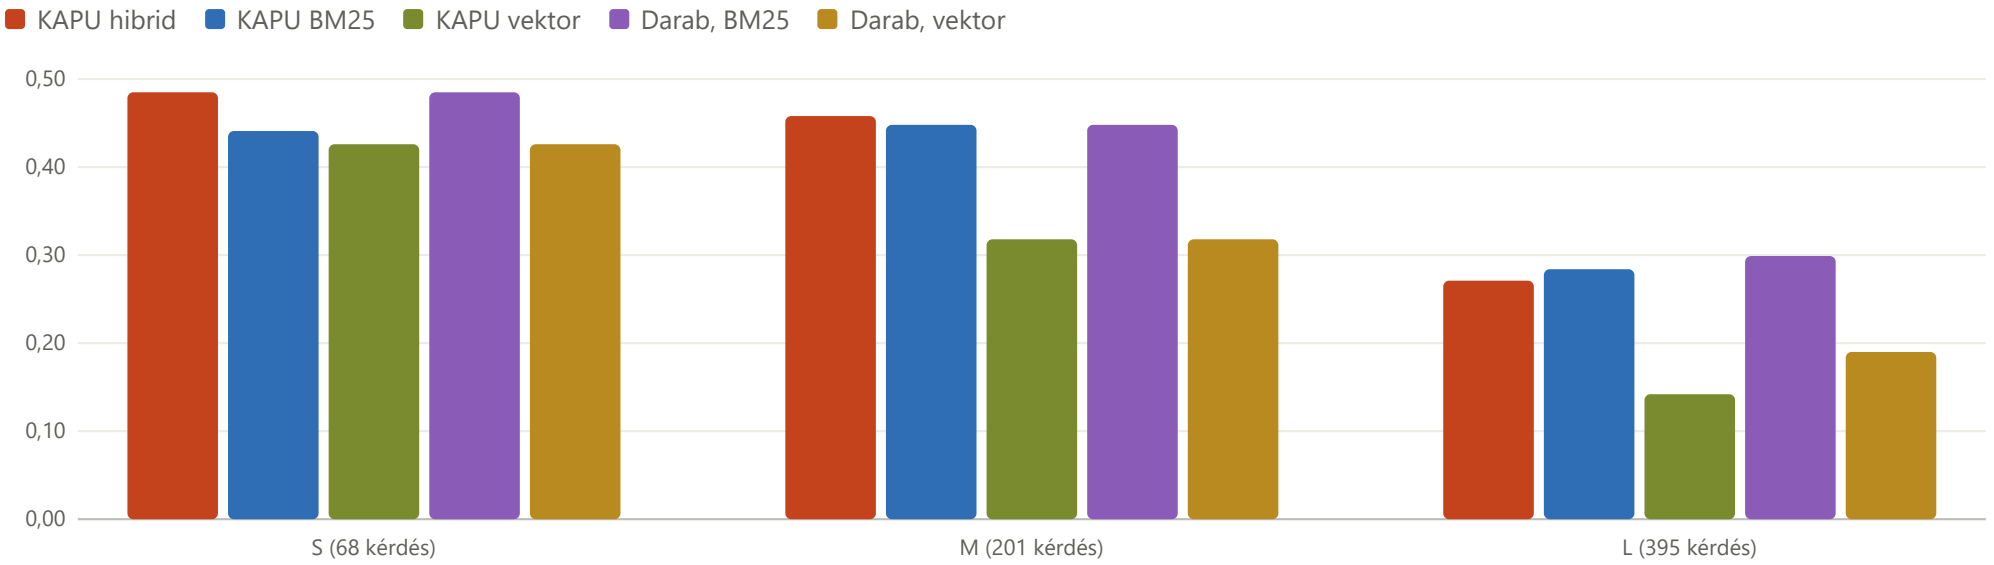
Méret	Korpusz	Tudás (token)	Szoba	Ajtó	Csoport	Build (s)	Memória (GB)	Fájl (MiB)	Térkép (token)	Első térkép (token)	Legnagyobb csoportlista (token)	Keresés (token)	Keresés (ms)	Első keresés (s)	Kinyitás (token)	Kinyitás (ms)
S	Rust book	321 618	111	231	7	4,6	0,69	2,2	153	322	804	246	12,8	1,1	1 689	2,4
M	Kubernetes	3 873 333	1 722	6 370	104	38	1,03	26,2	1 950	2 318	6 957	260	19,2	1	240	4,9
L	MDN	12 995 136	14 719	84 910	99	240,3	2,68	128,3	1 921	2 303	30 118	212	158,2	1,3	366	44,1

Visszakeresés ügynök nélkül: KAPU kontra darabolós RAG

Valódi Stack Overflow-kérdések, ahol az elfogadott válasz pontosan egy dokumentációoldalra hivatkozik: 68, 201 és 395 kérdés. Találat: az oldal bármely része az első találatok között. A darabolós alapvonal 512 tokenes darabokkal, 64 token átfedéssel és ugyanazzal a beágyazómodellel dolgozik.

Szobaszintű recall@10 méret és módszer szerint

A KAPU ajtókat ad vissza (szobákat és fejezeteiket), az alapvonal darabokat.



Méret	Módszer	Kérdés	Recall@5	Recall@10	MRR@10
S	KAPU hibrid	68	0,397	0,485	0,281
S	KAPU BM25	68	0,338	0,441	0,259
S	KAPU vektor	68	0,353	0,426	0,184
S	Darab, BM25	68	0,426	0,485	0,282
S	Darab, vektor	68	0,368	0,426	0,230
M	KAPU hibrid	201	0,373	0,458	0,245
M	KAPU BM25	201	0,348	0,448	0,218
M	KAPU vektor	201	0,219	0,318	0,147
M	Darab, BM25	201	0,338	0,448	0,218
M	Darab, vektor	201	0,249	0,318	0,145
L	KAPU hibrid	395	0,172	0,271	0,128
L	KAPU BM25	395	0,220	0,284	0,135
L	KAPU vektor	395	0,086	0,142	0,055
L	Darab, BM25	395	0,230	0,299	0,159

Méret	Módszer	Kérdés	Recall@5	Recall@10	MRR@10
L	Darab, vektor	395	0,124	0,190	0,081

Élő próba a Rust Bookon: öt rendszer, 30 kérdés

Ezekre a népszerű kérdésekre a modell fejből is jól válaszolt (zárt könyv: 30-ból 30), ezért itt a pontosság nem különbözteti meg a rendszereket, a költség igen. KAPU a v1.0.3-as specifikációval; a v1.0.4-gyel a KAPU-ügynökök kérdésenként mediánban 2331 tokent olvastak, azonos pontossággal.

Helyes válaszok és költség rendszerenként

Két vak bíráló (Claude Sonnet és Haiku). Az ügynök összes tokenje: a teljes futás a kérdésekre osztva, közelítés.

Rendszer	Helyes (Sonnet-bíráló)	Helyes (Haiku-bíráló)	Kérdés	Olvasott token/kérdés	Hívás/kérdés	Ügynök összes tokenje/kérdés
Zárt könyv, eszköz nélkül	30	28	30	0	0	2 706
Ügynöki darabolós RAG	30	27	30	4 150	1	12 648
grep/read a Markdown-mappán	29	28	30	1 290	2	9 343
llms.txt	30	29	30	8 738	2	11 615
KAPU	30	29	30	3 982	2	10 118

Korábbi javítókör: a v1.0.4-es specifikáció

Mérőszám	v1.0.3	v1.0.4
KAPU a Rust Bookon: olvasott token/kérdés (medián)	3 982	2 331
KAPU a Rust Bookon: helyes válasz (30-ból)	30	30
Első térképhívás, Kubernetes (token)	4 989	2 318
Első térképhívás, MDN (token)	4 139	2 303

Módszer és korlátok

- Korpuszok: a Rust Book (MIT vagy Apache-2.0), a Kubernetes-dokumentáció (CC BY 4.0) és az MDN Web Docs (CC BY-SA 2.5), rögzített commitokon. Kérdések: Stack Overflow API (CC BY-SA); csak az azonosítóik vannak tárolva.
- Ügynökök: Claude Sonnet alügynökök, csak naplózott eszközökkel. A tokenszámlálás o200k_base.
- Bírálók: vak Claude-modellek; a válaszok véletlen betűk alatt, a forrásjelölő sorok nélkül.
- Ez pilot egyetlen gépen (Windows 11, release build), nem benchmark. A PixelLab-fájl harmadik féltől való, nem publikus.

Repó RESULTS.md Nyers számok (JSON)